SimpleMC

Estimación de parámetros de modelos de energía oscura y otras curiosidades

Isidro Gómez Vargas¹

¹Instituto de Ciencias Físicas UNAM

CosmoMeeting III
Cuernavaca, Morelos, México
27 de noviembre de 2021

Contenido de la Contenido de l

- 1 Introducción
- 2 Estructura
- 3 Ejemplos
- 4 Cómo contribuir

Motivación

SimpleMC: toolbox for cosmological data analysis

J. Alberto Vázquez ^{1,a} Isidro Gómez-Vargas ^{1,b} A. Slosar ^{2,c}

¹Instituto de Ciencias Físicas, Universidad Nacional Autónoma de México, 62210, Cuernavaca, Morelos, México.

²Brookhaven National Laboratory, NY, USA.

November 26, 2021

 a javazquez@icf.unam.mx , b igomez@icf.unam.mx , c aslosar@slosar.com

https://github.com/ja-vazquez/SimpleMC

Análisis de datos

Estimación del Máximo Likelihood (MLE):

$$\ln \mathcal{L}(D,\theta) = \sum_{i=1}^{n} \ln f(x_i;\theta),$$

$$\theta_{MLE} = arg \ max(\mathcal{L}(D, \theta,))$$

Análisis de datos

Estimación del Máximo Likelihood (MLE):

$$\ln \mathcal{L}(D,\theta) = \sum_{i=1}^{n} \ln f(x_i;\theta),$$

$$\theta_{MLE} = arg \ max(\mathcal{L}(D, \theta,))$$

Estimación del A Posteriori (MAP) $P(\theta, D)$ ó estimación de parámetros ó inferencia Bayesiana. Por Teorema de Bayes:

$$P(\theta, D) = \frac{\mathcal{L}(D, \theta)P(\theta)}{P(D)}$$

y luego:

$$\theta_{MAP} = arg \ max(\mathcal{L}(D, \theta)P(\theta))$$

Análisis de datos

Estimación del Máximo Likelihood (MLE):

$$\ln \mathcal{L}(D,\theta) = \sum_{i=1}^{n} \ln f(x_i;\theta),$$

$$\theta_{MLE} = arg \ max(\mathcal{L}(D, \theta,))$$

Estimación del A Posteriori (MAP) $P(\theta, D)$ ó estimación de parámetros ó inferencia Bayesiana. Por Teorema de Bayes:

$$P(\theta, D) = \frac{\mathcal{L}(D, \theta)P(\theta)}{P(D)}$$

y luego:

$$\theta_{MAP} = arg \ max(\mathcal{L}(D, \theta)P(\theta))$$

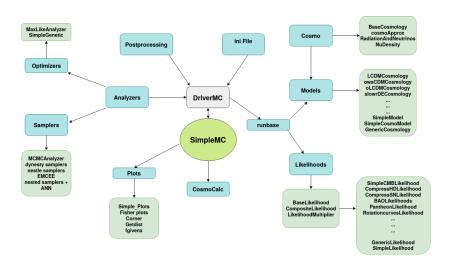
■ Comparación de modelos (puede ser parte de la inferencia Bayesiana).

- Comparación de modelos (puede ser parte de la inferencia Bayesiana).
- Reconstrucciones no paramétricas.

- Comparación de modelos (puede ser parte de la inferencia Bayesiana).
- Reconstrucciones no paramétricas.
- Visualización.

- Comparación de modelos (puede ser parte de la inferencia Bayesiana).
- Reconstrucciones no paramétricas.
- Visualización.
- Interpretación física.

Estructura



Modelos

| Modelo | Ecuación de Friedmann $\left(H^2/H_0^2\right)$ |
|---------------|---|
| ΛCDM | $\Omega_{cb}a^{-3} + \Omega_{\Lambda} + ho_{ u+r}(z)/ ho_{ m crit}$ |
| $o\LambdaCDM$ | $\Omega_{cb}a^{-3} + \Omega_{\Lambda} + ho_{ u+r}(z)/ ho_{ m crit} + \Omega_k a^{-2}$ |
| wCDM | $\Omega_{cb}a^{-3} + \Omega_{\mathrm{de}}a^{-3(1+w)} + \rho_{\nu+r}(z)/\rho_{\mathrm{crit}}$ |
| owCDM | $\Omega_{cb}a^{-3} + \Omega_{de}a^{-3(1+w)} + \rho_{\nu+r}(z)/\rho_{crit} + \Omega_k a^{-2}$ |
| $w_0 w_a CDM$ | $\Omega_{cb}a^{-3} + \Omega_{de}a^{-3(1+w_0+w_a)} \exp[-3w_a(1-a)] + \rho_{\nu+r}(z)/\rho_{crit}$ |

Modelos

| Modelo | Ecuación de Friedmann (H^2/H_0^2) |
|--|--|
| Slow Roll Dark Energy | $\Omega_{cb}a^{-3} + \rho_{\nu+r}(z)/\rho_{crit} + \Omega_{DE}\left[a^{-3}/(\Omega_m a^{-3} + \Omega_{DE})\right]^{\delta w_0/\Omega_{DE}}$ |
| ow ₀ w _a CDM | $\frac{\Omega_{cb}a^{-3} + \Omega_{de}a^{-3}(1+w_0+w_a)}{\Omega_{cb}a^{-3} + (\Omega_1 + \Omega_k)a^{-2} + \Omega_2a^{-1} + (1-\Omega_{cb} - \Omega_k - \Omega_1 - \Omega_2)}$ |
| PolyCDM | $\Omega_{cb}a^{-3} + (\Omega_1 + \Omega_k)a^{-2} + \Omega_2a^{-1} + (1 - \Omega_{cb} - \Omega_k - \Omega_1 - \Omega_2)$ |
| Early Dark Energy | See relevant section. |
| Decaying Dark Matter | See relevant section. |
| ν CDM | free neutrino mass $(\Sigma m_ u < 1\mathrm{eV})$ |
| $\Delta N_{ m eff}$ $\Lambda { m CDM}$ | non-standard radiation component ($2 < N_{ m eff} < 5)$ |

Datos

- SNIa
- Cronómetros cósmicos.
- BAO.
- Planck 2015 y 2018.- Versiones comprimidas de Planck-15 y Planck-18 (tratadas como un BAO a z = 1090)
- \bullet $f\sigma_8$

Analizadores

- Optimizadores.
- Algoritmo de inferencia Bayesiana.

Optimizadores

- MaxLikeAnalyzer.
- Algoritmo genético simple.

Inferencia Bayesiana

- Metropolis-Hastings .
- Muestreo anidado.
- Emcee.

Extras

- Métodos no paramétricos.
- MCEvidence.
- Redes neuronales.

Salidas y gráficas

SimpleMC arroja como salida un .paramnames, un resumen y, para inferencia Bayesiana, un formato compatible con CosmoMC que se puede graficar con:

- Simple_Plots (nativo).
- corner.
- getdist.
- fgivenx.

Otros

- CosmoCalc
- Archivo ini para configuración del usuario.
- MPI y multiprocessing

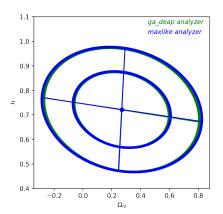
MLE

| maxlike | ga_deap | |
|--------------------|--------------------|--|
| [custom] | [custom] | |
| model = waCDM | model = waCDM | |
| datasets = SN+HD | datasets = SN+HD | |
| analyzer = maxlike | analyzer = ga_deap | |
| | population = 200 | |

MLE

| | maxlike | ga_deap |
|-----------------------|---------|---------|
| Ω_m | 0,2697 | 0,2683 |
| $\Omega_b h^2$ | 0,0220 | 0,02201 |
| h | 0,7221 | 0,7207 |
| w ₀ | -1,3668 | -1,3564 |
| W _a | 1,3103 | 1,3206 |
| $max\ log\mathcal{L}$ | 7,1334 | 7,1336 |

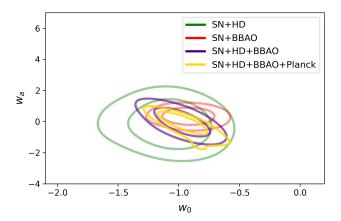
MLE



MAP

```
[custom]
model = waCDM
datasets = SN+HD
analyzer = mcmc
mcevidence = False
[mcmc]
GRstop = 0.01
nsamp = 10000
```

MAP



MAP

| | SN+HD | SN+BBAO | SN+HD | SN+BBAO+HD |
|----------------|----------------------|----------------------|----------------------|----------------------|
| Ω_m | $0,3050 \pm 0,0775$ | $0,2399 \pm 0,0472$ | $0,2993 \pm 0,0180$ | $0,3058 \pm 0,0103$ |
| $\Omega_b h^2$ | $0,0220 \pm 0,0005$ | $0,0220 \pm 0,0004$ | $0,0221 \pm 0,0005$ | $0,0224 \pm 0,0003$ |
| h | $0,6850 \pm 0,0324$ | $0,5865 \pm 0,0673$ | $0,6651 \pm 0,0206$ | $0,6769 \pm 0,0111$ |
| w ₀ | $-1,0202 \pm 0,1624$ | $-0,8932 \pm 0,0934$ | $-0,9420 \pm 0,0978$ | $-0,9592 \pm 0,0966$ |
| w _a | $-0,1983 \pm 0,9194$ | $0,4076 \pm 0,3272$ | $-0,1199 \pm 0,4291$ | $-0,0765 \pm 0,3715$ |
| max log L | 27,6746 | 23,5360 | 31,7931 | 30,7215 |

```
[custom]
model = LCDM
datasets = SN+HD
analyzer = nested
mcevidence = False
```

```
[custom]
model = LCDM
datasets = SN+HD
analyzer = mcmc
mcevidence = True
```

| Método | LCDM (Modelo 1) | CPL (Modelo 2) | |
|------------------|-----------------------|-----------------------|--|
| muestreo anidado | $-28,9465 \pm 0,1899$ | $-30,8858 \pm 0,2246$ | |
| mcmc+mcevidence | -35,8112 | -35,8611 | |

Calculando el factor de Bayes:

Calculando el factor de Bayes:

$$B_{12[nested]} = -28,947 \pm 0,19 - (-30,886 \pm 0,225)$$
 = 1,939 \pm 0,035 \Longrightarrow Ventaja significativa para el modelo 1

Calculando el factor de Bayes:

$$B_{12[nested]} = -28,947 \pm 0,19 - (-30,886 \pm 0,225)$$
 = 1,939 \pm 0,035 \Longrightarrow Ventaja significativa para el modelo 1

$$B_{12[mcevidence]} = -35.811 - (-35.861)$$

= 0.05 \Longrightarrow Ventaja poco convincente para el modelo 1

CosmoCalc

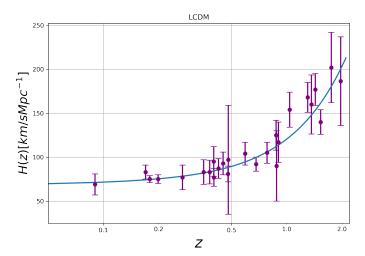
```
from simplemc.CosmoCalc import CosmoCalc

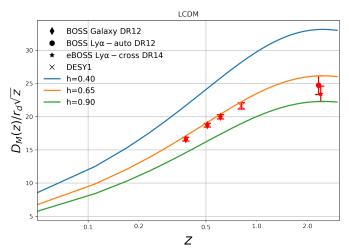
C_1 = CosmoCalc('LCDM', 'Hubble', plot_data=True, zmax=2.1)

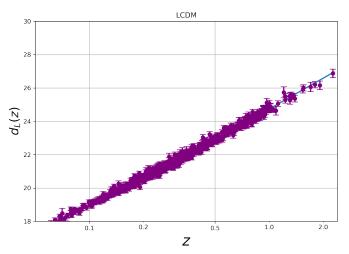
C_2 = CosmoCalc('LCDM', 'DaDverrd', 'h', 0.4, 0.9, plot_data=True)

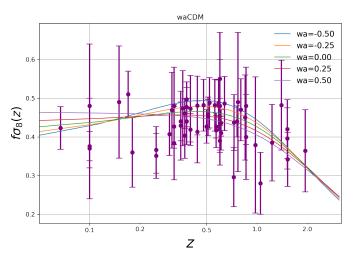
C_3 = CosmoCalc('LCDM', 'SNIa', plot_data=True, zmax=2.3)

C_4 = CosmoCalc('ovaCDM', 'fs8', 'wa', -0.5, 0.5, zmax=3.1, plot_data=True)
```

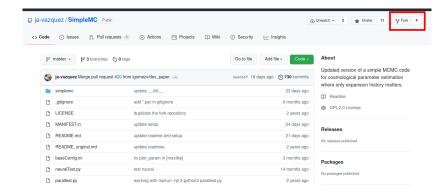




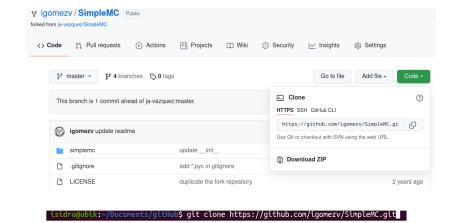




1. Fork al repositorio original



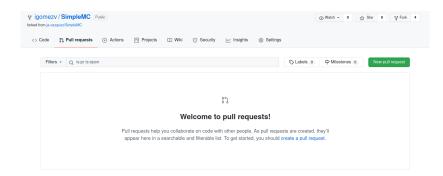
2. Clone a la copia



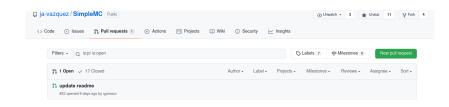
3. Commit y push a los cambios realizados en la copia

(base) isidro@ubik:-/Documents/gitHub/SimpleMC\$ git commit -m "add X parameterization in a new DE model" simplemc/runbase.py simplemc/models/new_model.py baseConfig.ini

4. Pull request al repo original



4. Pull request al repo original



Bonus

Explorar documentación si da tiempo. https://igomezv.github.io/SimpleMC/



Gracias.